

K-FNSPID v4: 미래 정보 누수를 통제한 한국 금융 뉴스·공시·시장반응 데이터셋

최성현

한국공학대학교 SW대학 컴퓨터공학부 소프트웨어전공
4학년 학부생

2026년 7월

초록

본 연구는 한국 상장시장의 뉴스 524,696건과 전자공시 722,989건을 파일 기반 일별 시세 10,691,998행에 연결한 금융 자연어처리 자원 K-FNSPID v4를 제안한다. 동결 배포본은 문서 1,247,685건, 문서-종목 관계 1,136,118건, 시장반응 표본 715,015건, 사건 혼입을 제거한 대표 표본 255,168건으로 구성된다. 본 연구는 발표 시각을 한국 거래 세션에 맞춰 정규화하고 유사 사건을 군집화한 뒤, 동일 종목·거래일의 서로 다른 사건 충돌을 제외하는 시간순 평가 절차를 설계했다. 본 실험을 통해 KF-DeBERTa LoRA의 감성분류 macro-F1이 균형 공개 시험셋에서 KR-FinBERT-SC의 0.7272보다 0.1578 높은 0.8850으로 향상됨을 확인했다. 또한 뉴스·공시 출처별 시장반응 전문가는 각 TF-IDF 기준선 대비 통합 macro-F1을 0.3210에서 0.3690으로, quadratic weighted kappa를 0.2552에서 0.3975로 향상시켰다. 두 출처의 거래일 군집 bootstrap 신뢰구간은 모두 0을 넘었다. 공시의 의미 중요도는 별도 910건 코드북 평가셋에서 검증했다. 본 데이터와 모델은 의미 중요도, 사후 시장반응, 인과효과를 구분하며 투자수익을 주장하지 않는다.

1 서론

금융 모니터링 시스템은 문장의 긍정·부정뿐 아니라 어떤 사건이 어느 종목에 언제 중요한지도 판단해야 한다. 이를 위해서는 텍스트, 종목 연결, 거래 세션 시각과 시세를 함께 다루고, 미래 사건이 모델 선택에 들어가지 않는 평가가 필요하다. 본 논문에서 시간 경계 누수는 분할 경계 이후에 발표된 문서, 같은 사건의 중복 문서 또는 미래 구간에서 계산된 통계가 이전 구간의 전처리·보정·모델 선택에 영향을 주는 현상을 뜻한다. FNSPID는 미국 종목 뉴스와 시세를 대규모로 연결하지만 [1], 한국 시장의 공시 식별자, 거래 세션과 회사 별칭을 그대로 표현하지 못한다. KRX Bench와 FINKRX는 한국 금융 지식과 질의응답을 평가하므로 [2, 3], 문서 단위 시장반응 분류와는 과제가 다르다.

본 연구의 기여는 다음과 같다. 첫째, 뉴스·공시 1,247,685건과 전 종목 일별 시세 10.69M행을 비공개 DB가 아닌 검증 가능한 Parquet 파일로 배포한다. 둘째, 발표 세션 정규화, 사건 중복 군집화, 종목-거래일 충돌 제거와 7일 embargo를 결합해 시간 경계 누수를 통제한다. 셋째, 감성·의미 중요도·사후 시장반응을 서로 다른 과제로 정의한다. 넷째, 뉴스·공시 출처별 전문가, 공시 3개 seed, calibration과 통계 검정을 함께 보고한다. 공개 시스템명은 Hana Montana AI(KF-DeBERTa + K-FNSPID)이다.

2 관련 연구

FNSPID는 1999년부터 2023년까지 S&P 500 기업 4,775개에 대해 뉴스 15.7M건과 시세 29.7M행을 제공한다 [1]. 문서-기업-시세 연결 구조는 K-FNSPID의 스키마 설계 참고 대상으로 활용하지만, 시장·언어·공시 체계가 달라 성능 수치를 직접 비교하지 않는다. KRX Bench와 FINKRX는 각각 한국 금융 지식과 instruction 기반 질의응답 평가를 제공한다 [2, 3]. 두 자원은 한국 금융 평가 범위를 정하는 데 활용하되, 문서별 사후 시장반응과 과제가 달라 수치 기준선에서는 제외한다. MultiFinBen은 다언어·다중모달 금융 평가와 전문가 검증 절차를 확장하며 [4], 후속 다중모달 평가 설계의 참고 대상으로 사용한다.

금융 감성은 시간 분포 이동에 따라 성능이 저하될 수 있다 [5]. 이 결과는 무작위 분할 대신 시간 외삽 평가를 채택하는 근거가 된다. FININ은 뉴스 간 상호작용과 가격을 결합해 시장예측을 수행한다 [6]. 수익률 최적화가 목적인 FININ과 달리 본 논문의 직접 비교 과제는 관측 시장반응의 4등급 순서형 분류로 한정한다. 한국 금융 말뭉치로 사전학습한 KF-DeBERTa [7]와 저랭크 적응 기법 LoRA [8]는 출처별 Transformer 전문가의 기반 방법으로 사용한다.

3 데이터셋 구축

3.1 원천과 규모

뉴스는 상장기업 별칭을 기준으로 Naver 검색 결과에서 추출하고, 공시는 OpenDART에서 수집한다. 각 문서는 발표시각, 원천, 제공자, URL 기반 provenance와 정규화 텍스트를 보존한다. 문서-종목 관계는 종목코드와 대표 연결 여부를 포함한다. 시장반응 행은 유효 거래일, 미래 반응 특징, 순서형 라벨, split, 충돌 여부와 사건 군집 ID를 저장한다.

OpenDART 전체 목록과 원천 식별자를 연결하고 응답 크기 제한, timeout, 재시도, ZIP 검증과 상태코드 기록을 적용해 배포 공시 8,972건의 원문을 확보했다. 이는 전체 배포 공시 722,989건의 1.24%다. 최종 추가수집 대상 5,082건 중 4,976건을 저장했으며, 실패 106건은 본문 부족 51건, DART 상태 013 1건, 상태 014 37건, 공개 뷰어 metadata 부재 17건으로 기록했다. 복구 원문은 Gold가 아니며, Gold URL을 제거한 실제 공시 8,302건은 의미 중요도 학습 후보로만 사용하고 감성 정답으로 사용하지 않는다.

구성요소	건수
뉴스 문서	524,696
OpenDART 공시	722,989
전체 문서	1,247,685
문서-종목 관계	1,136,118
시장반응 행	715,015
비혼입 대표행	255,168
일별 시세 행	10,691,998
연결된 공시 원문	8,972
기본 의미 Gold	680

표 1: 동결 K-FNSPID v4 배포본의 규모.

3.2 Gold와 주석

기본 운영 Gold는 뉴스 80건과 공시 600건이다. 공시 중요도 분포는 LOW 250, MEDIUM 34, HIGH 287, CRITICAL 29이며, 감성은 부정 55, 중립 475, 긍정 70이다. 정책 경계를 검증하는 공시 stress set 310건을 더해 의미 중요도 평가는 총 910건이다. 학습과 Gold의 URL 중복은 0건이다.

코드북은 등급 우선순위, 증거 필드, 감성 override, 모호 사례 제외와 종목별 상한을 고정한다. 상장폐지, 횡령·배임, 감사의견 거절, 부도·회생·파산과 같은 존속 위험만 CRITICAL로 제한한다. 단순 거래정지나 불성실공시 지정은 HIGH다. 단, Gold는 공개 코드북을 따른 단일 Codex 기반 검수자가 판정했다. 독립 금융전문가 다중 주석이나 평가자 간 일치도가 없으므로 정책 보강 결과를 외부 SOTA로 해석하지 않는다.

3.3 거래일과 사건 정규화

장 마감 전 문서는 같은 유효 거래일, 마감 후·주말·휴일 문서는 다음 거래일에 배정한다. 같은 사건의 반복 보도는 유효 거래일과 정규화 내용을 포함한 지문으로 묶는다. 같은 종목·거래일에 서로 다른 사건 군집이 둘 이상 존재하면 혼입으로 표시해 기본 학습에서 제외한다. 같은 사건·종목·거래일 안에서는 정보량이 가장 큰 문서를 대표로 선택한다.

4 과제와 라벨

감성. 부정·중립·긍정 언어를 예측한다. 균형 공개 시험셋은 등급별 311건, 총 933건이며 운영 뉴스·공시 Gold로 원천 이동을 확인한다.

의미 중요도. 공시 의미가 기업에 주는 중요도를 LOW, MEDIUM, HIGH, CRITICAL로 분류한다. 시장의 예상 여부와 무관하게 안정적이어야 한다.

사후 시장반응. 수정주가와 동일 시장 평균수익률의 차이를 1·3·5거래일에 계산한다. 1일 절대 초과수익률, 3일 절대 초과수익률, 60일 로그 거래량 z-score 충격, 20일 일중 변동성 충격에 각각 0.50, 0.20, 0.15, 0.15의 가중치를 적용하고 합성 점수를 $[0, 1]$ 로 제한한다. 이 점수를 $0 \leq s < 0.20$ 이면 LOW, $0.20 \leq s < 0.45$ 이면 MEDIUM, $0.45 \leq s < 0.75$ 이면 HIGH, $0.75 \leq s \leq 1$ 이면 CRITICAL로 구분한다. 미래 관측값은 정답 생성에만 사용하므로, 이 등급은 인과적 중요도나 거래 신호가 아닌 관측 시장반응의 순서형 대리변수다.

모델	Accuracy	Macro-F1
TF-IDF logistic	0.4780	0.4423
KR-FinBERT-SC	0.7363	0.7272
KF-DeBERTa LoRA	0.8853	0.8850
80:20 ensemble	0.8842	0.8840
Logistic stacker	0.8821	0.8820

표 2: 균형 공개 감성 Test 933건.

5 누수 통제 실험

출처별 비혼입 대표셋에서 뉴스는 Train 99,826건, Validation 6,391건, Test 9,560건이고 공시는 각각 119,146건, 584건, 4,615건이다. Validation은 2026년 1월 1일, Test는 2026년 4월 1일부터 시작하며 각 경계 직전 7일을 embargo한다. 전처리, 사전확률·temperature 보정, 조기 종료와 모델 선택은 Test를 사용하지 않는다. 통계 비교는 출처 안에서 문서 ID와 정답이 같은 경우에만 수행한다.

감성 모델은 고정 revision의 kakaobank/kf-deberta-base에 LoRA rank 16, $\alpha = 32$, dropout 0.1을 사용한다. 배포 감성은 KF-DeBERTa와 TF-IDF logistic 확률을 0.8:0.2로 결합한다. Validation으로 학습한 stacker도 평가했지만 독립 시험과 운영 Gold가 낮아 배포하지 않았다.

의미 중요도는 제목, 제목+요약, 제목+요약+전문의 TF-IDF logistic을 Validation으로 비교한다. 제목+요약과 제목의 macro-F1은 0.9894로 같지만 Brier score가 각각 0.00134와 0.00156이어서 제목+요약을 선택했다. 전문 모델은 0.9815로 낮아 강제 사용하지 않는다. 존속위험 문구에는 좁은 결정적 floor만 적용하고 모델 단독과 정책 보강 결과를 분리한다.

시장반응은 뉴스와 공시 기준선·Transformer·보정을 분리한다. 공시 신경망은 KF-DeBERTa LoRA rank 16, 128 token, 유효 batch 32, learning rate 5×10^{-5} 를 사용한다. loss는 class-balanced focal cross entropy($\gamma = 1.0$), 가중치 0.20의 ordinal CDF MSE와 label smoothing 0.01을 결합한다. 공시 seed 17, 42, 73 중 Validation macro-F1만으로 seed 17을 선택한다. 뉴스는 v4 Test를 보기 전에 동결한 검증 adapter를 뉴스 전용으로 재평가한다. 요청 출처와 artifact 출처가 다르면 추론을 거부한다.

지표는 accuracy, macro-F1, quadratic weighted kappa(QWK), 순서형 MAE, 15-bin ECE와 다중분류 Brier score다. 2,000회 paired bootstrap, exact 양측 McNemar와 70개 시험 거래일을 단위로 한 2,000회 군집 bootstrap을 사용한다.

6 결과

6.1 감성분류

KF-DeBERTa는 KR-FinBERT-SC보다 macro-F1이 0.1579 높다. paired bootstrap 차이는 0.1566, 95% CI는 $[0.1262, 0.1877]$ 이고 exact McNemar $p = 1.51 \times 10^{-18}$ 이다. 80:20 ensemble은 공개 시험 점수가 근소하게 낮지만 뉴스 Gold에서 accuracy 0.9000/macro-F1 0.8642, 공시 Gold에서 0.9233/0.8344를 기록해 운영 견고성을 위해 유지한다.

출처/모델	Acc.	M-F1	QWK
뉴스 TF-IDF	0.4715	0.3484	0.3421
뉴스 KF-DeBERTa	0.5247	0.3745	0.4754
공시 TF-IDF	0.3675	0.2677	0.1125
공시 KF-DeBERTa [†]	0.4750	0.3216	0.1550
통합 출처 라우팅	0.5085	0.3690	0.3975

표 3: 시장반응 Test: 뉴스 9,560 건, 공시 4,615 건. [†] Validation만으로 선택.

원천	모델	M-F1	QWK
뉴스 9,560	TF-IDF	0.3484	0.3421
	KF-DeBERTa	0.3745	0.4754
공시 4,615	TF-IDF	0.2677	0.1125
	KF-DeBERTa	0.3216	0.1550

표 4: 원천별 시장반응 Test.

6.2 공시 의미 중요도

제목+요약 모델 단독은 기본 공시 Gold 600건에서 accuracy 0.9850, macro-F1 0.9470, CRITICAL F1 0.8163이다. 기존 v3 이전 통합 분석기의 0.7150/0.4489/0.2619보다 높다. 좁은 코드북 floor를 더하면 기본셋 1.0000, 기본+stress 910건에서 accuracy 0.9989, macro-F1 0.9962, QWK 0.9994를 기록한다. 이는 같은 코드북으로 만든 floor와 평가셋의 내부 일치도이므로 독립 외부 타당성이 아니다. 모델 단독 결과를 기본 과학 결과로 해석한다.

6.3 시간 외삽 시장반응

통합 출처별 전문가는 기준선보다 macro-F1이 0.0479, QWK가 0.1422 높다. 거래일 군집 bootstrap 95% CI는 accuracy [0.0594, 0.0818], macro-F1 [0.0351, 0.0608], QWK [0.1178, 0.1649]로 모두 0을 넘고, McNemar $p = 2.29 \times 10^{-55}$ 이다. ECE도 0.0369에서 0.0259로 개선된다. 공시 3-seed Test macro-F1은 0.3170 ± 0.0052 이며 선택 seed 17은 0.3216이다.

6.4 원천별 비회귀 분석

뉴스 Macro-F1 차이의 거래일 군집 95% CI는 [0.0120, 0.0409], 공시는 [0.0264, 0.0806]이다. QWK 차이는 각각 [0.1090, 0.1558], [0.0046, 0.0794]다. 이전 공유 모델의 공시 회귀를 출처별 학습으로 제거했지만 공시 QWK 하한이 0에 가까워 추가 기간 재현이 필요하다.

7 Ablation과 운영 비교

이전 공유 모델은 공시 Test가 590건뿐이었고 macro-F1이 0.3006에서 0.2211로 하락했다. 공시 원천을 722,989문서로 확장해 비혼입 Test 4,615건을 만들고 전용 전문가를 학습하자 0.3216으로 개선됐다. 과거 TF-IDF ablation에서는 제목+요약이 전문보다 높았으므로 공시 전문 8,972건을 보존하되 장문 입력 자체를 개선 원인으로 주장하지 않는다.

v3 전환은 기존 운영셋 일부에서 회귀한다. 실제 뉴스 감성 accuracy는 0.9750에서 0.9000, stock-review 감성은 0.9180에서 0.7880, 실제 뉴스 중요도는 0.9625에서 0.9500, stock-review 중요도는 0.8480에서 0.8060, 사건

macro-F1은 0.7307에서 0.7110으로 하락한다. 과거 라벨 정책과 새 과제가 일부 충돌하지만 이 회귀를 숨기지 않고 과제별 gate와 fallback을 유지한다.

8 논의와 결론

K-FNSPID v4의 주된 기여는 예측 과제의 완결보다 한국 금융 데이터 인프라와 평가 규율이다. 하나의 공유 시장반응 모델은 공시 회귀를 숨겼지만 출처별 전문가는 뉴스와 공시를 모두 같은 Test에서 개선한다. 또 의미 중요도와 가격반응을 API에서 분리해야 한다. 파산 공시는 시장이 예상했더라도 의미상 중요하고, 확인되지 않은 소문은 큰 가격변화를 만들더라도 신뢰할 중요 사건은 아닐 수 있다.

FNSPID보다 절대 문서 수는 적지만 한국 공시, 세션 정규화, 사건 혼입 필드, embargo split과 파일 배포를 추가한다. KRX Bench와 FINKRX보다 과제 범위는 좁고 사건 연결에 집중한다. 따라서 교차 benchmark SOTA나 수익성은 주장하지 않는다. 동일 Test의 명시된 기준선 대비 개선, 그리고 공개 코드북에 대한 내부 일치만 방어 가능한 주장이다.

한계

Naver 검색 결과는 질의, 제공자, 중복 제거와 생존 편향의 영향을 받는다. OpenDART 전문 커버리지는 1.24%이며 결측은 무작위가 아니다. 회사 별칭은 사명 변경, 약어와 상장폐지 종목을 놓칠 수 있다. 일봉은 장중 반응, 발표 전 정보 누출과 거시·산업·동시 사건 혼입을 제거하지 못한다. 시장반응은 상관적 약지도다.

기본 Gold 680건과 stress 310건은 전체 말뭉치보다 작다. 특히 공시 Gold는 단일 Codex 기반 판정자가 고정 코드북으로 검수했다. 독립 금융전문가 2인 이상, 합의 과정과 평가자 간 일치도가 없다. 시장반응 Test는 유효 거래일 70개이며 공시는 34개 거래일이다. 공시 QWK 개선 구간의 하한은 0.0046으로 작다. 한국어와 2026년 경계에 한정돼 지역·기간 일반화도 제한된다.

윤리적 고려

공개 뉴스·공시·시세도 저작권, 개인정보와 맥락 보존 문제가 사라지는 것은 아니다. 배포는 연구 목적 정책, provenance, 삭제와 버전 절차를 따른다. API key, credential과 비공개 사용자 데이터는 제외한다. 기업 사건에 포함된 개인 식별자는 downstream에서 접근 통제와 목적 제한이 필요하다.

금융 NLP는 소문, 시세조종과 자동화 편향을 증폭할 수 있다. API는 의미 중요도와 관측 시장반응을 분리하고 confidence와 모델 버전을 반환하며, artifact hash나 승격 gate가 실패하면 검증된 fallback으로 fail closed한다. 자동 주문이나 개인화 투자 조언을 수행하지 않으며 고위험 알림은 원문 확인과 사람의 판단이 필요하다.

생성형 코딩 보조 도구는 데이터 엔지니어링, 코드 검토, 코드북 기반 Gold 검수와 원고 작성에 사용됐다. 모든 수치는 버전이 고정된 기계 판독 보고서와 대조한다. 이 사용은 서로 연관된 주석·서술 오류를 만들 수 있으며 독립 전문가 검증은 대체하지 않는다.

재현성

환경은 Python 3.12와 lockfile을 사용한다. base model revision, LoRA 설정, 공시 seed, optimizer, scheduler, 완료 epoch와 Validation 선택값을 보고서에 저장한다. Parquet은 byte size와 SHA-256을 manifest에 기록한다. 출처별 기준선·Transformer prediction으로 재학습 없이 paired 평가가 가능하다. remote model code는 비활성화하고 safetensors와 artifact version·source·path·size·hash를 확인한 뒤 로드한다. 논문 표의 핵심 수치는 빌드 전에 동결 JSON과 자동 대조한다.

A 배포 파일과 승격 조건

배포본은 documents.parquet, document_entities.parquet, market_impacts.parquet, prices_daily.parquet, splits.parquet, annotations.parquet으로 구성한다. 애플리케이션 DB에서 데이터셋을 재구성하지 않는다.

감성 승격은 공개 Test macro-F1 0.85 이상, 동일 ID에서 KR-FinBERT-SC 이상, 뉴스·공시 운영 Gold 각각 accuracy 0.90 이상을 요구한다. 뉴스 시장반응은 Test 5,000건·macro-F1 0.35·QWK 0.30, 공시는 500건·0.30·0.08 이상을 요구한다. 두 출처 모두 ECE 0.20 이하, 자체 기준선 비회귀, source metadata와 artifact 무결성을 통과해야 한다. 연구 우위는 출처별 거래일 군집 bootstrap 하한이 0보다 커야 한다.

참고문헌

- [1] Zihan Dong, Xinyu Fan, and Zhiyuan Peng. FN-SPID: A comprehensive financial news dataset in time series. In Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining, 2024. URL <https://arxiv.org/abs/2402.06698>.
- [2] Guijin Son, Hyunjun Jeon, Chami Hwang, and Hanearl Jung. KRX bench: Automating financial benchmark creation via large language models. In Proceedings of the Joint Workshop of FinNLP, KDF, and ECONLP, pages 10–20, 2024. URL <https://aclanthology.org/2024.finnlp-1.2/>.
- [3] Guijin Son, Hyunwoo Ko, Hanearl Jung, and Chami Hwang. FINKRX: Establishing best practices for Korean financial NLP. In Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics: Industry Track, pages 1161–1174, 2025. doi: 10.18653/v1/2025.acl-industry.81.
- [4] Xueqing Peng, Lingfei Qian, Yan Wang, et al. MultiFinBen: Benchmarking large language models for multilingual and multimodal financial application. In Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics, pages 16934–16963, 2026. doi: 10.18653/v1/2026.acl-long.770.
- [5] Yue Guo, Chenxi Hu, and Yi Yang. Predict the future from the past? on the temporal data distribution shift in financial sentiment classifications. In Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing, pages 1029–1038, 2023. doi: 10.18653/v1/2023.emnlp-main.65.
- [6] Mengyu Wang, Shay B. Cohen, and Tiejun Ma. Modeling news interactions and influence for financial market prediction. In Findings of the Association for Computational Linguistics: EMNLP 2024, pages 3302–3314, 2024. doi: 10.18653/v1/2024.findings-emnlp.189.
- [7] Eunkwang Jeon, Jungdae Kim, Minsang Song, and Joohyun Ryu. KF-DeBERTa: Financial domain-specific pre-trained language model. In Proceedings of the 35th Annual Conference on Human and Cognitive Language Technology, pages 143–148. Korean Institute of Information Scientists and Engineers, 2023. URL <https://huggingface.co/kakaobank/kf-deberta-base>.
- [8] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. LoRA: Low-rank adaptation of large language models. In International Conference on Learning Representations, 2022. URL <https://openreview.net/forum?id=nZeVKeeFYf9>.